

Anexo: Evaluación de Usabilidad del Sistema (SUS)

Evaluación de Calidad del Software / Trabajo de Fin de Grado

8 de octubre de 2026

1. Objetivo del anexo

El presente anexo describe la metodología, aplicación práctica y análisis estadístico de la evaluación de usabilidad percibida del sistema desarrollado. El propósito fundamental es cuantificar objetivamente la experiencia del usuario y el grado de facilidad de uso de la herramienta mediante un instrumento validado psicométricamente y estandarizado a nivel industrial.

2. ¿Qué es el SUS?

La escala **System Usability Scale (SUS)** fue concebida originariamente por John Brooke en 1986 y formalmente publicada en la literatura científica en 1996 (Brooke 1996). Es catalogada comúnmente como una herramienta «rápida y flexible» (*quick and dirty*) para recopilar de forma ágil la percepción global sobre la usabilidad de un sistema tecnológico.

El cuestionario consta de diez afirmaciones estructuradas sobre una escala de tipo Likert (Likert 1932) de cinco niveles de respuesta (desde «Totalmente en desacuerdo» hasta «Totalmente de acuerdo»). El SUS evalúa tres dimensiones fundamentales de la usabilidad definidas por el estándar ISO 9241-11:

- **Eficacia:** la capacidad del usuario de culminar las tareas con éxito.
- **Eficiencia:** la inversión proporcional de recursos y tiempo requerida.
- **Satisfacción:** la comodidad subjetiva y aceptación global manifestada.

3. Tabla de preguntas SUS

Para evitar sesgos de respuesta sistemáticos y la aquiescencia de los participantes, el cuestionario alterna intencionadamente afirmaciones en sentido positivo (ítems impares) y afirmaciones en sentido negativo (ítems pares), tal como se detalla en el Cuadro 1.

4. Tabla de puntuaciones de la escala Likert

Cada participante puntúa individualmente cada una de las afirmaciones asignando un valor discreto entero del 1 al 5 (Cuadro 2).

5. Cómo se calcula

La puntuación global del SUS no corresponde a la suma directa de las respuestas, sino a una transformación normalizada que sitúa el resultado en un rango continuo de 0 a 100 puntos.

Para cada participante con respuestas $q_1, q_2, \dots, q_{10} \in \{1, 2, 3, 4, 5\}$, se calculan las contribuciones individuales c_i :

Ítem	Polaridad	Enunciado en español	Orientación
q_1	Impar	Creo que me gustaría utilizar este sistema con frecuencia.	Positivo
q_2	Par	Encontré el sistema innecesariamente complejo.	Negativo
q_3	Impar	Pensé que el sistema era fácil de usar.	Positivo
q_4	Par	Creo que necesitaría el apoyo de una persona técnica para utilizar este sistema.	Negativo
q_5	Impar	Encontré que las diversas funciones del sistema estaban bien integradas.	Positivo
q_6	Par	Pensé que había demasiada inconsistencia en este sistema.	Negativo
q_7	Impar	Imagino que la mayoría de la gente aprendería a utilizar este sistema muy rápidamente.	Positivo
q_8	Par	Encontré el sistema muy engorroso de usar.	Negativo
q_9	Impar	Me sentí muy seguro utilizando el sistema.	Positivo
q_{10}	Par	Necesité aprender muchas cosas antes de poder empezar a utilizar este sistema.	Negativo

Tabla 1: Formulación en español de los 10 ítems de la escala SUS.

Puntuación asignada	Significado semántico
1	Totalmente en desacuerdo
2	En desacuerdo
3	Neutral / Indeciso
4	De acuerdo
5	Totalmente de acuerdo

Tabla 2: Opciones de respuesta de la escala Likert de 5 puntos.

- Para ítems impares ($i \in \{1, 3, 5, 7, 9\}$): $c_i = q_i - 1$ (escala 0 a 4).
- Para ítems pares ($i \in \{2, 4, 6, 8, 10\}$): $c_i = 5 - q_i$ (escala 0 a 4).

La puntuación SUS final se obtiene sumando las 10 contribuciones y multiplicando el total por 2,5:

$$\text{Puntuación SUS} = 2,5 \times \sum_{i=1}^{10} c_i = 2,5 \times \left(\sum_{k=1}^5 (q_{2k-1} - 1) + \sum_{k=1}^5 (5 - q_{2k}) \right) \quad (1)$$

Ejemplo detallado de cálculo con el primer participante:

A modo de demostración, se detalla el cálculo para el participante **U1** (Cliente):

- **Respuestas brutas:** $q_1 = 5, q_2 = 1, q_3 = 5, q_4 = 1, q_5 = 4, q_6 = 2, q_7 = 5, q_8 = 1, q_9 = 5, q_{10} = 1$.
- **Contribuciones de ítems impares** ($q_i - 1$): $c_1 = 5 - 1 = 4, c_3 = 5 - 1 = 4, c_5 = 4 - 1 = 3, c_7 = 5 - 1 = 4, c_9 = 5 - 1 = 4$.
- **Contribuciones de ítems pares** ($5 - q_i$): $c_2 = 5 - 1 = 4, c_4 = 5 - 1 = 4, c_6 = 5 - 2 = 3, c_8 = 5 - 1 = 4, c_{10} = 5 - 1 = 4$.
- **Suma de contribuciones:**

$$\sum_{i=1}^{10} c_i = 4 + 4 + 4 + 4 + 3 + 3 + 4 + 4 + 4 + 4 = 38$$

■ **Puntuación SUS final:**

$$\text{SUS} = 38 \times 2,5 = \mathbf{95,0}$$

Esta puntuación de 95,0 equivale a una calificación **A+**, adjetivo **El mejor imaginable** y aceptabilidad **Aceptable**.

6. Cómo se transforma

Una puntuación SUS en la escala de 0 a 100 **no** debe ser interpretada como un porcentaje simple ni como una nota académica tradicional. En la literatura empírica se ha determinado que la puntuación media global de referencia industrial es de **68 puntos** sobre 100. Puntuaciones superiores a 68 denotan una usabilidad por encima del promedio estándar.

6.1. Escala de calificaciones curvada (Sauro y Lewis, 2016)

Sauro y Lewis (2016) establecieron una escala normativa percentilada que asigna calificaciones de la «A+» a la «F» basada en la distribución acumulada empírica de miles de evaluaciones (Cuadro 3).

Rango SUS	Nota	Rango percentil	Interpretación
$\geq 84,1$	A+	96–100 %	Usabilidad superior y altamente diferenciada
80,8 – 84,0	A	90–95 %	Excelente usabilidad
78,9 – 80,7	A-	85–89 %	Muy buena usabilidad
77,2 – 78,8	B+	80–84 %	Usabilidad notable superior al promedio
74,1 – 77,1	B	70–79 %	Buena usabilidad
72,6 – 74,0	B-	65–69 %	Ligeramente por encima de la media
71,1 – 72,5	C+	60–64 %	En el promedio alto
65,0 – 71,0	C	41–59 %	En la media (incluye referencia SUS = 68)
62,7 – 64,9	C-	35–40 %	Ligeramente por debajo del promedio
51,7 – 62,6	D	15–34 %	Usabilidad deficiente con problemas serios
$< 51,7$	F	0–14 %	Inaceptable / Fracaso de usabilidad

Tabla 3: Curva de notas y percentiles normalizados según Sauro y Lewis (2016).

6.2. Escala de adjetivos (Bangor, Kortum y Miller, 2009)

Bangor et al. (2009) determinaron empíricamente las puntuaciones medias asociadas a 7 adjetivos descriptivos. Debido a que el artículo original aporta la media de cada término y no intervalos cerrados, se adoptan como umbrales de decisión los puntos medios entre medias adyacentes (Cuadro 4).

Adjetivo descriptivo	Media original	Umbral operativo	Rango aplicado
El mejor imaginable	90,9	$\geq 88,20$	[88,20, 100,0]
Excelente	85,5	$\geq 78,45$	[78,45, 88,20)
Bueno	71,4	$\geq 61,15$	[61,15, 78,45)
OK	50,9	$\geq 43,30$	[43,30, 61,15)
Pobre	35,7	$\geq 28,00$	[28,00, 43,30)
Horrible	20,3	$\geq 16,40$	[16,40, 28,00)
El peor imaginable	12,5	$< 16,40$	[0,00, 16,40)

Tabla 4: Adjetivos de usabilidad y umbrales basados en Bangor et al. (2009).

6.3. Rangos de aceptabilidad (Bangor, Kortum y Miller, 2008)

Por último, Bangor et al. (2008) categorizan la viabilidad operativa en tres franjas determinantes:

- **Aceptable** ($SUS \geq 70,0$): La interfaz cumple satisfactoriamente las expectativas de interacción.
- **Marginal** ($50,0 \leq SUS < 70,0$): La usabilidad presenta deficiencias notables que requieren corrección prioritaria antes del despliegue.
- **No aceptable** ($SUS < 50,0$): El sistema impone barreras severas para su operabilidad.

7. Introducción a los resultados

La evaluación empírica se llevó a cabo con una muestra de $n = 5$ participantes representativos de los distintos perfiles de usuario del sistema. Los participantes interactuaron de forma independiente con los módulos de la aplicación, ejecutando tareas clave de flujo de trabajo completo antes de cumplimentar el cuestionario de manera individual.

8. Perfiles de los participantes

El Cuadro 5 recoge los perfiles funcionales evaluados junto con las observaciones cualitativas más destacadas aportadas por cada participante.

ID	Perfil	Comentario del participante
U1	Cliente	Visualización de métricas clave sin editar fórmulas
U2	Encargado	Interfaz limpia y ágil
U3	Operador	Fácil de aprender en el primer turno de trabajo
U4	Administrador	Gestión de permisos intuitiva y bien organizada
U5	Auditor	El flujo de auditoría es claro aunque requiere habituarse

Tabla 5: Identificación, perfil funcional y aportaciones cualitativas de la muestra.

9. Tabla de resultados

En el Cuadro 6 se compilan las respuestas brutas a los 10 ítems Likert, la puntuación SUS computada, la calificación normativa y los descriptores para cada participante.

ID	q1	q2	q3	q4	q5	q6	q7	q8	q9	q10	SUS	Nota	Adjetivo	Aceptabilidad
U1	5	1	5	1	4	2	5	1	5	1	95,0	A+	El mejor imaginable	Aceptable
U2	4	2	5	1	5	1	4	2	4	1	87,5	A+	Excelente	Aceptable
U3	4	2	4	2	4	2	4	2	4	2	75,0	B	Bueno	Aceptable
U4	5	1	4	1	5	2	5	1	5	1	95,0	A+	El mejor imaginable	Aceptable
U5	3	2	4	2	3	1	4	2	4	2	72,5	C+	Bueno	Aceptable
Media muestral (μ)											85,0	A+	Excelente	Aceptable
Desviación típica muestral (s)											10,75	—	—	—
Puntuación mínima											72,5	—	—	—
Puntuación máxima											95,0	—	—	—

Tabla 6: Matriz consolidada de respuestas y estadísticos descriptivos del SUS.

10. Interpretación de resultados

El sistema evaluado ha obtenido una puntuación media global de **85,0** sobre 100, con una dispersión muestral de $s = 10,75$. La puntuación más baja registrada fue de 72,5 puntos y la más alta alcanzó los 95,0 puntos.

Este resultado sitúa al sistema en la calificación **A+**, correspondiente al adjetivo cualitativo «**Excelente**» y catalogado como **Aceptable** en la clasificación de viabilidad operativa.

Al situarse por encima del umbral normativo estándar de 68 puntos, la usabilidad global del sistema se considera superior a la media de la industria. La calificación de aceptabilidad **Aceptable** confirma que los usuarios logran completar los flujos habituales sin fricción crítica, cumpliendo satisfactoriamente los criterios funcionales requeridos. **Análisis cualitativo del evaluador:**

- **Puntos fuertes destacados:** [Completar: aspectos positivos y tareas ejecutadas con mayor agilidad].
- **Principales dificultades detectadas:** [Completar: tareas con más problemas o dudas manifestadas].
- **Acciones de mejora propuestas:** [Completar: cambios de interfaz, retroalimentación o simplificación de flujos].




Figura 1: Calificación y adjetivo global.




Figura 2: Ubicación en zona de aceptabilidad.




Figura 3: Distribución del intervalo muestral (mínimo, media y máximo) respecto al umbral SUS (68).




Figura 4: Puntuación individualizada por participante comparada frente a la media de referencia de la industria.

Referencias bibliográficas

- Bangor, A., Kortum, P. T., & Miller, J. T. (2008). An Empirical Evaluation of the System Usability Scale. *International Journal of Human-Computer Interaction*, 24(6), 574-594. <https://doi.org/10.1080/10447310802205776>
- Bangor, A., Kortum, P. T., & Miller, J. T. (2009). Determining What Individual SUS Scores Mean: Adding an Adjective Rating Scale. *Journal of Usability Studies*, 4(3), 114-123.
- Brooke, J. (1996). SUS: A 'Quick and Dirty' Usability Scale. En P. W. Jordan, B. Thomas, I. L. McClelland & B. Weerdmeester (Eds.), *Usability Evaluation in Industry* (pp. 189-194). Taylor & Francis.
- Likert, R. (1932). A Technique for the Measurement of Attitudes. *Archives of Psychology*, 22(140), 1-55.
- Sauro, J., & Lewis, J. R. (2016). *Quantifying the User Experience: Practical Statistics for User Research* (2nd). Morgan Kaufmann.